



KUHAS

KUHAS CURRICULUM DATA ANALYSIS

2024년 2학기
데이터분석 커리큘럼
멘토 권세은

www.kuhas.korea.ac.kr

CONTENTS

- 1 데이터 분석은 무엇인가?
- 2 데이터 수집 방법
- 3 Tool 설명 및 사용법
- 4 커리큘럼 진행 계획

데이터 분석은 무엇인가?

1) 개념과 필요성

Q. 데이터 분석이란?

유용한 인사이트를 발견하기 위해 데이터를 수집, 정리, 조작, 분석 하는 전 과정임

Q. 데이터 분석은 왜 필요한가요?

- 데이터에 기반하여 효율적인 의사결정 만듦
- **효율성 최대화, 비용 감소, 성과 향상, 문제 해결, 미래 예측** 등에 큰 기여를 함

때문에 거의 **모든 산업에서 폭넓게 사용** 중이며
데이터의 양이 기하급수적으로 증가함에 따라 **중요성은 더욱 커질 것**


데이터 분석은 무엇인가?

2) 과정




데이터 분석은 무엇인가?

2) 과정




데이터 분석은 무엇인가?


3) 과정




데이터 수집 방법



공공데이터포털
(www.data.go.kr)




국가통계포털
(kosis.kr)



KAGGLE
(kaggle.com)



마이크로데이터 통합 서비스
(mdis.kostat.go.kr)



DAICON
(dacon.io)

그 외: Awesome Public Datasets, Google AI Datasets, Google Dataset Search, AI hub...

Tool 설명 및 사용법

1) Google Colab (구글 코랩)

- 클라우드 기반 **Jupyter Notebook** 환경
 - 대화형 컴퓨팅 환경
 - 마크다운으로 문서에 텍스트와 수학적 표현 포함 가능
- 웹 브라우저에서 **Python** 코드를 작성, 실행할 수 있음
 - C, C++ 등 다른 프로그래밍 언어도 컴파일 가능 But 주 목적은 Python 프로그래밍
- **구글 드라이브와 연동**하여 노트북 파일을 저장하고 공유 가능
- 다양한 라이브러리와 프레임워크가 설치되어 있어 추가적인 설치나 설정 없이 바로 사용 가능함

1. Series

1차원 데이터 (정수, 실수, 문자열 등)

```
import pandas as pd
```

```
# Series 객체 생성  
# 예) 1월부터 4월까지 평균 온도 데이터 (-20, -10, 10, 20)  
  
temp = pd.Series([-20, -10, 10, 20])  
temp
```

```
0  
0 -20  
1 -10  
2 10  
3 20
```

dtype: int64

명령 프롬프트

```
Microsoft Windows [Version 10.0.18363.535]  
(c) 2019 Microsoft Corporation. All rights reserved.  
  
C:\Users\#B80K>pip install pandas
```


Tool 설명 및 사용법

2) Pandas

1. 중소 규모 데이터 처리에 최적화

- 작업 중인 전체 데이터셋을 메모리에 보관
대용량 데이터셋 처리엔 비효율적

2. 데이터 조작에 필요한 다양한 기능 제공

- 데이터 구조화 및 분석 쉬움
- 데이터 필터링, 변환, 집계 등 데이터 조작 관련
다양한 기능 제공

3. 데이터 시각화 가능

```
import pandas as pd
data = {
    '영화' : ['명량', '극한직업', '신과함께-죄와 벌', '국제시장', '괴물', '도둑들', '7번방의 선물', '암살'],
    '개봉 연도' : [2014, 2019, 2017, 2014, 2006, 2012, 2013, 2015],
    '관객 수' : [1761, 1626, 1441, 1426, 1301, 1298, 1281, 1270], # (단위 : 만 명)
    '평점' : [8.88, 9.20, 8.73, 9.16, 8.62, 7.64, 8.83, 9.10]
}
df = pd.DataFrame(data)
df
```

4. 주어진 계산식을 참고하여 '추천 점수' column을 추가하시오

추천 점수 = (관객수 * 평점) // 100

```
[ ] df['추천 점수'] = df['관객 수'] * df['평점'] // 100
df
```

<새로운 정보 생성>

```
df.groupby('학교').get_group('북산고')
```

	이름	학교	키	국어	영어	수학	과학	사회	SW특기
지원번호									
1번	채치수	북산고	197	90	85	100	95	85	Python
2번	정대만	북산고	184	40	35	50	55	25	Java
3번	송태섭	북산고	168	80	75	70	80	75	Javascript
4번	서태웅	북산고	187	40	60	70	75	80	NaN
5번	강백호	북산고	188	15	20	10	35	10	NaN

<원하는 정보 추출>


Tool 설명 및 사용법

3) Matplotlib


특정 기능을 수행하기 위해 미리 작성된 코드의 집합

- 파이썬 데이터시각화 라이브러리
- 넘파이로 다양한 형태의 그래프 쉽게 그릴 수 있도록 설계됨

```
plt.bar(index - w, df['국어'], width=w, label='국어')  
plt.bar(index, df['영어'], width=w, label='영어')  
plt.bar(index + w, df['수학'], width=w, label='수학')  
plt.legend(ncol=3)  
plt.xticks(index, df['이름'], rotation=60)
```



```
plt.pie(values, labels=labels, explode=explode, autopct='%1.1f%%',  
startangle=90, counterclock=False, colors=colors)
```



커리큘럼 진행 계획

날짜	수업 내용
9.10	OT & 환경 설정
9.17	추석 휴강
9.24	Pandas 내용 정리 및 예제 연습
10.1	Matplotlib 내용 정리 및 예제 연습
10.8~29	중간고사 휴강
11.5	실습1
11.12	실습2
11.19	개인 프로젝트 1차
11.26	개인 프로젝트 2차

- 자료에 있는 모든 코드 직접 쳐보면서 함수 공부
- 수업 때는 학습한 함수 예제로 연습
- 중간고사 이후 실습해보면서 전체적인 데이터 분석 과정 익히기
- 개인프로젝트 정해서 데이터에서 본인만의 인사이트가 담긴 결과 만들어보기

QnA